

**МИНОБРНАУКИ РОССИИ**  
**САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ**  
**ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ**  
**«ЛЭТИ» ИМ. В. И. УЛЬЯНОВА (ЛЕНИНА)**

**Кафедра математического обеспечения и применения ЭВМ**

**ОТЧЕТ**  
**по практической работе №5**  
**по дисциплине «Машинное обучение»**

Студент гр. 1310

Комаров Д. Е.

Преподаватель

Жангиров Т.Р.

Санкт-Петербург

2025

## Задание 1

### Постановка задачи

Дан набор значений 2, 4, 10, 12, 3, 20, 30, 11, 25. Предположим количество кластеров  $k = 3$ , и выбраны начальные средние значения  $m_1 = 2$ ,  $m_2 = 4$ ,  $m_3 = 6$ . Покажите, какие кластеры будут сформированы после первой итерации алгоритма k-средних, и рассчитайте новые значения центров кластеров для следующей итерации.

### Код программы

```
import numpy as np

D=[2, 4, 10, 12, 3, 20, 30, 11, 25]
startM=[2, 4, 6]

def kMeans(D,startM,iters):
    M=startM
    for i in range(iters):
        clust=[[ ] for j in range(len(M)) ]
        for d in D:
            delt=(d-m)**2 for m in M
            clust[delt.index(min(delt))].append(d)
        M=[float(np.mean(cl)) for cl in clust]
    return (clust,M)

clust,M=kMeans(D,startM,1)
print(clust)
print(M)
```

### Результат выполнения

В результате выполнения программы после первой итерации алгоритма были сформированы следующие кластеры: [2, 3], [4], [10, 12, 20, 30, 11, 25]. Новые значения центров кластеров для следующей итерации: [2.5, 4.0, 18.0].

## Задание 2

### Постановка задачи

Набор точек  $x$  и вероятности из принадлежности к кластерам  $C_1$  и  $C_2$  представлен в таблице 1.

Таблица 1 – Набор точек для 2 задания

$x$	$P(C_1 x)$	$P(C_2 x)$
2	0.9	0.1
3	0.8	0.1
7	0.3	0.7
9	0.1	0.9
2	0.9	0.1
1	0.8	0.2

Необходимо выполнить следующие задания:

1. Найди оценку максимального правдоподобия для средних  $\mu_1$  и  $\mu_2$ ;
2. Предположим, что  $\mu_1 = 2$ ,  $\mu_2 = 7$  и  $\sigma_1 = \sigma_2 = 1$ . Необходимо найти вероятности принадлежности точки  $x = 5$  к кластерам C1 и C2. Априорные вероятности каждого кластера  $P(C1) = P(C2) = 0.5$  и  $P(x = 5) = 0.029$ .

### Код программы

```
import math
X=[
    (2,[0.9,0.1]),
    (3,[0.8,0.1]),
    (7,[0.3,0.7]),
    (9,[0.1,0.9]),
    (2,[0.9,0.1]),
    (1,[0.8,0.2]),
]
k=2
M=[sum(x[0]*x[1][kit] for x in X)/sum([x[1][kit] for x in X]) for kit in range(k)]
print(M)

x=5
M=[2,7]
std=[1,1]
C=[0.5,0.5]
f=[(1/(math.sqrt(2*math.pi)*std[kit]))*math.exp(-pow(x-M[kit],2)/(2*std[kit]**2)) for kit in range(k)]
P=[f[kit]*C[kit]/sum(f[kk]*C[kk] for kk in range(k)) for kit in range(k)]
print(P)
```

### Результат выполнения

- 1)  $\mu_1=2.58$ ;  $\mu_2=6.62$ ;
- 2)  $P(C1 | x) = 0.08$ ;  $P(C2 | x) = 0.92$ ;

### Задание 3

#### Постановка задачи

Категориальные данные размерности 5 представлены в таблице 2.

Таблица 2 – Категориальные данные для 3 задания

Point	$X_1$	$X_2$	$X_3$	$X_4$	$X_5$
$\mathbf{x}_1$	1	0	1	1	0
$\mathbf{x}_2$	1	1	0	1	0
$\mathbf{x}_3$	0	0	1	1	0
$\mathbf{x}_4$	0	1	0	1	0
$\mathbf{x}_5$	1	0	1	0	1
$\mathbf{x}_6$	0	1	1	0	0

Близость двух наблюдений определяется через количество совпадений и несовпадений значений признаков. Допустим, что  $n_{11}$  количество признаков одновременно равных 1 для наблюдений  $x_i$  и  $x_j$ , и  $n_{10}$  количество признаков равных 1 для наблюдения  $x_i$  и в то же время равных 0 для наблюдения  $x_j$ . По аналогии определяются значения  $n_{01}$  и  $n_{00}$ .

Определим следующие метрики.

Коэффициент простого совпадения

$$SMC(\mathbf{x}_i, \mathbf{x}_j) = \frac{n_{11} + n_{00}}{n_{11} + n_{10} + n_{01} + n_{00}}.$$

Коэффициент Жаккара

$$JC(\mathbf{x}_i, \mathbf{x}_j) = \frac{n_{11}}{n_{11} + n_{10} + n_{01}}.$$

Коэффициент Рассела и Рао

$$RC(\mathbf{x}_i, \mathbf{x}_j) = \frac{n_{11}}{n_{11} + n_{10} + n_{01} + n_{00}}.$$

Необходимо построить дендограммы полученные после иерархической кластеризации при следующих параметрах:

- метод одиночной связи с метрикой RC;
- метод полной связи с метрикой SMC;
- невзвешенный центроидный метод с метрикой JC.

### Код программы

```
import networkx as nx
import matplotlib.pyplot as plt
from scipy.spatial.distance import squareform
from scipy.cluster.hierarchy import dendrogram, linkage

X=[
    [1,0,1,1,0],
    [1,1,0,1,0],
    [0,0,1,1,0],
    [0,1,0,1,0],
    [1,0,1,0,1],
    [0,1,1,0,0]
]
points = ['x1', 'x2', 'x3', 'x4', 'x5', 'x6']

N11=[[sum([1 if x1[i] and x2[i] else 0 for i in range(len(x1))])for x2 in X]for x1 in X]
N10=[[sum([1 if x1[i] and (not x2[i]) else 0 for i in range(len(x1))])for x2 in X]for x1 in X]
N01=[[sum([1 if (not x1[i]) and x2[i] else 0 for i in range(len(x1))])for x2 in X]for x1 in X]
```

```

N00=[[sum([1 if (not x1[i]) and (not x2[i]) else 0 for i in range(len(x1))])for
x2 in X]for x1 in X]

SMC=[[1-(N11[i][j]+N00[i][j])/(N11[i][j]+N10[i][j]+N01[i][j]+N00[i][j])for j
in range(len(X))]for i in range(len(X))]
JC=[[1-N11[i][j]/(N11[i][j]+N10[i][j]+N01[i][j])]for j in range(len(X))]for i in
range(len(X))]
RC=[[0 if i==j else(1-N11[i][j]/(N11[i][j]+N10[i][j]+N01[i][j]+N00[i][j]))for j
in range(len(X))]for i in range(len(X))]

linkage_rc = linkage(squareform(RC), method='single')
dendrogram(linkage_rc, labels=points)
plt.show()

linkage_smc = linkage(squareform(SMC), method='complete')
dendrogram(linkage_smc, labels=points)
plt.show()

linkage_jc = linkage(squareform(JC), method='centroid')
dendrogram(linkage_jc, labels=points)
plt.show()

```

## Результат выполнения

- 1) Дендрограмма, построенная при помощи метода одиночной связи с метрикой RC представлена на рисунке 1.




Рисунок 1 – Дендрограмма, построенная при помощи метода одиночной связи с метрикой RC

- 2) Дендрограмма, построенная при помощи метода полной связи с метрикой SMC представлена на рисунке 2.




Рисунок 2 – Дендрограмма, построенная при помощи метода полной связи с метрикой SMC

3) Дендрограмма, построенная при помощи невзвешенного центроидного метода с метрикой JC представлена на рисунке 3.




Рисунок 3 – Дендрограмма, построенная при помощи невзвешенного центроидного метода с метрикой JC